Tugas Proyek dalam Kelompok
Audio Deepfake Anomaly Detection Harness
(ADADeH)
II4050 Rekayasa Sistem Multimedia

Oleh

Samuel Chris M.B.S. 18223011
Carlen Asadel Axelle 18223017
Ananda Fajrul Zidan 18223067



PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG
November 2026

DAFTAR ISI

DAFTAR GAMBAR

DAFTAR TABEL

DAFTAR PERSAMAAN

DAFTAR ALGORITMA

DAFTAR *LISTING*

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
AI	*Artificial Intelligence*	1
CNN	*Convolutional Neural Network*	2
GPU	*Graphics Processing Unit*	14

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama kali
α	Koefisien bobot untuk *loss function*, tingkat signifikansi statistik	75
β	Koefisien bobot untuk *Binary Cross-Entropy loss*	75
λ	Koefisien bobot untuk CTC *loss*, parameter regularisasi	75
θ	Parameter model *neural network*	75
σ	Deviasi standar	75
μ	Rata-rata (*mean*)	75
ϵ	*Token blank*/kosong dalam CTC, konstanta kecil untuk stabilitas numerik	75
Δ	Delta (selisih/perubahan nilai)	75
π	*Alignment path* dalam CTC	75
π_t	*Token* pada *timestep* t dalam *alignment path*	76
∇ atau ∂	Operator gradien atau turunan parsial	75
$\sum$	Operator penjumlahan	75
$\prod$	Operator perkalian	75
$\int$	Operator integral	75
argmax	Argumen yang memaksimalkan fungsi	76
$\sim$	Terdistribusi menurut	75
$\rightarrow$	Menuju atau konvergen ke	75
$\mathcal{L}$	Fungsi *loss* (kerugian)	75
$\mathcal{L}_{total}$	Total *loss function*	75
$\mathcal{L}_{adversarial}$ atau $\mathcal{L}_{adv}$	*Adversarial loss*	75
$\mathcal{L}_{reconstruction}$	*Reconstruction loss*	75
$\mathcal{L}_{L1}$	L1 *loss* (*Mean Absolute Error*)	75
$\mathcal{L}_{L2}$	L2 *loss* (*Mean Squared Error*)	75
$\mathcal{L}_{CTC}$	CTC (*Connectionist Temporal Classification*) *loss*	75
$\mathcal{L}_{perceptual}$	*Perceptual loss*	75

$\mathcal{L}_{pixel}$	*Pixel-wise loss*	75
$\mathcal{L}_{BCE}$	*Binary Cross-Entropy loss*	75
$\mathcal{L}_{GAN}$	GAN *loss*	75
$\mathcal{L}_{cycle}$	*Cycle consistency loss*	75
G	*Generator* dalam GAN	75
D	*Discriminator* dalam GAN	75
$G(z)$	*Output* dari *generator* dengan *input* z	75
$D(x)$	*Output* dari *discriminator* dengan *input* x	75
$G_{A \to B}$	*Generator* dari domain A ke B	75
$G_{B \to A}$	*Generator* dari domain B ke A	75
$V(D, G)$	Fungsi nilai (*value function*) dalam GAN	75
x	Sampel data asli, *input* citra	75
y	Label atau *ground truth*, kondisi dalam *conditional GAN*	75
z	*Noise vector* atau representasi laten	
$\mathbb{E}$	Ekspektasi atau nilai harapan	75
p_{data}	Distribusi data asli	75
p_z	Distribusi *prior* (*noise*)	75
$p(y\|x)$	Probabilitas bersyarat *output* y *given input* x	75
$p_t(\pi_t\|x)$	Probabilitas *token* pada *timestep* t	
$\mathcal{B}$	Fungsi penciutan (*collapse function*) dalam CTC	75
$\mathcal{B}^{-1}$	Fungsi invers penciutan dalam CTC	75
T	Jumlah *timestep* atau panjang *sequence*	
$\|x - G(y)\|_1$	L1 *distance* antara *ground truth* dan *generated image*	75
$\|x - G(y)\|_2$	L2 *distance* antara *ground truth* dan *generated image*	75
$N \times N$	Ukuran *patch* dalam PatchGAN	
d	Cohen's d (*effect size*)	75
n	Jumlah sampel	75
p	*p-value* (nilai probabilitas statistik)	75

r	Koefisien korelasi	75
R^2	Koefisien determinasi	
$O(n)$	Notasi Big-O untuk kompleksitas linear	75
$O(n^2)$	Notasi Big-O untuk kompleksitas kuadratik	75

BAB I

PENDAHULUAN

I.1 Latar Belakang

Tindak kriminal pada ruang digital yang memanfaatkan *artificial intelligence* (AI) untuk memanipulasi audio/suara manusia kian meningkat dan sangat memprihatinkan. AI dimanfaatkan para pelaku kejahatan untuk membuat *deepfake audio* yang ditujukan kepada korban sebagai modus penipuan atau pemerasan. Kebanyakan korban teperdaya oleh hasil manipulasi tersebut, yang mengakibatkan kerugian pada banyak aspek, khususnya kerugian finansial.

Para pelaku kejahatan melakukan hal tersebut dengan tujuan untuk menutup identitas aslinya. Metode tersebut berpotensi menimbulkan fitnah digital, manipulasi alat bukti elektronik, hingga kesalahan identifikasi dalam proses penegakan hukum (**Iman_2026**). Upaya penegakkan hukum untuk memberantas permasalahan ini memerlukan bantuan forensik digital. Forensik digital diperlukan dalam memperoleh bukti-bukti digital, termasuk bukti *deepfake audio* yang dibuat AI. Namun, hal ini hanya dapat dilaksanakan pada laboratorium forensik digital yang memfasilitasi proses perolehan serta pendeteksian bukti digital oleh para ahli.

Saat ini, laboratorium forensik digital hanya ada di Dittipidsiber Mabes Polri dan Polda Metro Jaya. Selain itu, keterbatasan fasilitas tersebut pun diiringi dengan kurangnya ahli forensik digital, khususnya ahli yang memahami AI generatif (**SIP_Law_Firm_2025**). Keterbatasan ini menimbulkan kesulitan bagi para korban yang ingin melakukan pelaporan atau pembuktian. Korban harus merekam audio sebagai bukti sah yang selanjutnya dilimpahkan kepada institusi terkait untuk diproses.

Oleh karena itu, diperlukan suatu metode yang mempermudah korban untuk mendeteksi *deepfake audio* buatan AI. Para penulis menggagas platform bertajuk *Audio Deepfake Anomaly Detection Harness* (ADADeH) untuk memerangi manipulasi AI dengan AI (AI vs AI) yang dilatih untuk mendeteksi *deepfake audio*. Dengan demikian, pembuktian tidak perlu melalui serangkaian prosedur yang rumit.

I.2 Rumusan Masalah

Keterbatasan sarana pembuktian yang ada menimbulkan beberapa persoalan dalam menghadapi kejahatan berbasis *deepfake audio*. Proses pendeteksian saat ini bergantung pada laboratorium forensik digital dan tenaga ahli yang jumlahnya terbatas, sehingga korban sulit mendapatkan indikasi awal atas rekaman yang diterimanya. Selain itu, suara hasil AI generatif kian menyerupai suara asli manusia sehingga tidak dapat dibedakan hanya dengan pendengaran. Di sisi lain, hasil deteksi yang ada umumnya belum disajikan dalam bentuk yang mudah dipahami masyarakat awam.

Apabila persoalan-persoalan ini tidak segera ditangani, korban akan tetap kesulitan melakukan pelaporan dan pembuktian, sementara pelaku dapat terus memanfaatkan *deepfake audio* untuk menutupi identitasnya. Oleh karena itu, tugas proyek ini mengusulkan ADADeH, yaitu platform berbasis AI yang mendeteksi anomali pada rekaman audio untuk membedakan suara asli manusia dari *deepfake audio*.

Berdasarkan hal tersebut, rumusan masalah setidaknya mencakup hal-hal berikut.

1. Bagaimana mendeteksi anomali pada rekaman audio yang membedakan suara asli manusia dari *deepfake audio* hasil AI generatif?
2. Bagaimana merancang *pipeline* ADADeH, mulai dari ekstraksi fitur audio hingga klasifikasi, dan evaluasi kinerja menggunakan metrik yang sesuai?
3. Bagaimana menyajikan hasil deteksi ADADeH secara mudah sebagai indikasi awal pembuktian, tanpa bergantung pada laboratorium forensik digital?

I.3 Tujuan

Berdasarkan latar belakang dan rumusan masalah yang telah diuraikan, tujuan dari TPdK ini adalah mengembangkan ADADeH, yaitu *platform* berbasis AI untuk mendeteksi *deepfake audio* sehingga dapat memberikan indikasi awal pembuktian bagi korban tanpa bergantung pada laboratorium forensik digital. Secara rinci, tujuan tersebut dijabarkan sebagai berikut.

1. Membangun model deteksi anomali yang dapat membedakan suara asli manusia dari *deepfake audio* hasil AI generatif berdasarkan karakteristik akustik rekaman.
2. Merancang dan mengimplementasikan *pipeline* yang mencakup ekstraksi fitur audio, klasifikasi, dan evaluasi kinerja dengan metrik yang sesuai.
3. Menyajikan hasil deteksi dalam bentuk yang mudah dipahami orang awam sebagai indikasi awal pembuktian.

Tugas proyek ini dinyatakan berhasil apabila ketiga tujuan tersebut tercapai. Kriteria keberhasilan yang digunakan adalah sebagai berikut.

1. Model deteksi mencapai akurasi dan *F1-score* minimal 90% serta *Equal Error Rate* (EER) maksimal 10% pada data uji yang tidak digunakan dalam proses pelatihan.
2. *Pipeline* ADADeH dapat dijalankan secara utuh, mulai dari masukan rekaman audio hingga keluaran hasil klasifikasi, tanpa adanya intervensi manual.
3. Hasil deteksi ditampilkan dalam bentuk yang dapat dipahami oleh pengguna awam, yaitu label klasifikasi beserta tingkat keyakinan model.

I.4 Lingkup dan Batasan

Lingkup dan batasan pengembangan ADADeH adalah sebagai berikut.

1. ADADeH membantu korban kejahatan berbasis *deepfake audio* memperoleh indikasi awal atas keaslian suatu rekaman. Sistem mencakup pemrosesan rekaman audio, ekstraksi fitur, klasifikasi suara asli dan suara hasil AI generatif, serta penyajian hasil deteksi kepada pengguna.
2. Pelatihan dan pengujian model menggunakan satu *dataset* publik Kaggle berisi rekaman berbahasa Inggris. Kinerja sistem pada teknik *deepfake* lain di luar *dataset* dan pada rekaman berbahasa Indonesia belum dapat dipastikan.
3. Sistem hanya melakukan klasifikasi biner untuk membedakan suara asli dan *deepfake audio*, tanpa mengidentifikasi pelaku maupun teknik pembuatan *deepfake* yang digunakan.
4. Masukan sistem berupa rekaman audio dalam format digital dengan kualitas rekaman yang memadai. Rekaman dengan *noise* yang sangat tinggi atau durasi yang terlalu singkat dapat menurunkan akurasi deteksi.
5. Hasil deteksi tidak menggantikan pemeriksaan forensik digital oleh ahli di laboratorium forensik digital.
6. Pengembangan dibatasi hingga integrasi dan pengujian purwarupa. Penerapan dalam skala luas dan pemeliharaan sistem belum menjadi bagian dari tugas proyek ini.

I.5 Metodologi Pengembangan

Pengembangan ADADeH menggunakan model *waterfall* dari analisis kebutuhan hingga integrasi dan pengujian. Keluaran setiap tahap menjadi dasar tahap berikutnya. Hasil akhirnya adalah purwarupa yang dapat dijalankan dan didemonstrasikan. Selain itu, pendekatan *Cross-Industry Standard Process for Data Mining* (CRISP-DM) digunakan untuk memandu penyiapan data audio, pemodelan, dan evaluasi model sebelum diintegrasikan ke dalam purwarupa. Jika hasil evaluasi belum memenuhi target, data atau model disempurnakan sebelum integrasi akhir yang bersifat iteratif sampai seluruh komponen tervalidasi.

1. **Analisis kebutuhan.** Masalah *deepfake audio* dan kebutuhan pengguna ditelaah melalui latar belakang serta literatur. Kebutuhan fungsional dan nonfungsional dirumuskan, lalu sedikitnya tiga alternatif solusi dibandingkan dengan matriks keputusan.
2. **Perancangan.** Arsitektur purwarupa dan aliran data dirancang dari masukan audio, prapemrosesan, ekstraksi fitur, dan klasifikasi hingga keluaran label serta tingkat keyakinan dalam teks. Perancangan juga mencakup pemisahan data latih dan uji serta antarmuka bagi pengguna awam.
3. **Implementasi.** Rekaman berbahasa Inggris dari *Audio Deepfake Detection Dataset* di Kaggle disiapkan. Komponen pemrosesan audio, model klasifikasi suara asli dan *deepfake audio*, serta antarmuka purwarupa dibangun sesuai rancangan.
4. **Integrasi dan pengujian.** Komponen digabungkan menjadi alur otomatis dari rekaman hingga hasil klasifikasi. Pada data uji yang tidak digunakan untuk pelatihan, matriks konfusi digunakan untuk menghitung akurasi dan *F1-score*. Model ditargetkan mencapai kedua metrik tersebut minimal 90% serta *Equal Error Rate* (EER) maksimal 10%. Evaluasi pengguna menilai keterpahaman label dan tingkat keyakinan.

I.6 Sistematika Penulisan

Laporan tugas proyek ADADeH disusun dalam enam bab sebagai berikut.

1. **Bab I Pendahuluan.** Bab ini memuat latar belakang, rumusan masalah, tujuan, lingkup dan batasan, metodologi pengembangan, serta sistematika penulisan.
2. **Bab II Dasar Teori.** Bab ini membahas konsep sistem multimedia, karakteristik audio dan *deepfake audio*, dasar pemrosesan dan deteksi audio, serta kajian solusi atau penelitian terkait.
3. **Bab III Analisis Kebutuhan.** Bab ini menjelaskan kebutuhan pengguna dan sistem, sedikitnya tiga alternatif solusi, serta dasar pemilihan solusi yang dikembangkan.
4. **Bab IV Desain dan Implementasi.** Bab ini menguraikan arsitektur ADADeH, aliran pengolahan audio, rancangan antarmuka, dan implementasi purwarupa.
5. **Bab V Pengujian dan Diskusi.** Bab ini menyajikan pengujian sistem dan model, evaluasi pengguna, serta pembahasan hasil dan keterbatasannya.
6. **Bab VI Kesimpulan dan Saran.** Bab ini menyimpulkan pencapaian tujuan ADADeH dan menyampaikan saran pengembangan.

BAB II

DASAR TEORI

II.1 Data Multimedia dan Representasinya

Keberadaan data merupakan suatu hal yang krusial dalam proses pengembangan platform ADADeH. Data yang menjadi fondasi utama pengembangan ADADeH merupakan data multimedia. Pengembangan platform ini setidaknya mencakup dua data multimedia: (1) audio sebagai data utama dan (2) citra spektrogram frekuensi audio terhadap waktu yang menjadi masukan model. Data-data tersebut berkontribusi dalam mengklasifikasi audio asli dan audio buatan AI generatif (*deepfake audio*).

II.1.1 Data Audio

Menurut **winer2025audio<empty citation>**, audio pada dasarnya adalah gelombang suara berbentuk pola kompresi dan ekspansi yang merambat melalui medium tertentu pada rentang frekuensi yang dapat didengar manusia. Rentang tersebut ada pada kisaran 20 Hz–20 kHz (**wikipedia2026hearingrange**). Medium rambat gelombang suara umumnya adalah udara. Pada produksi musik atau audio digital, apabila gelombang tersebut ditangkap dari udara oleh media elektronik seperti mikrofon, suara dapat direpresentasikan sebagai sinyal listrik yang dialirkan melalui kabel atau sirkuit.

Dalam TPdK ini, audio berperan sebagai data primer yang diolah dan nantinya dilatih model. Pemanfaatan audio sebagai data perlu memerhatikan beberapa hal, yaitu:

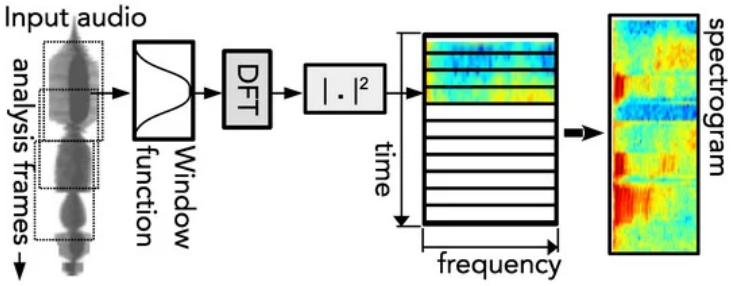
(a). *Sampling rate* (*sr*). Menurut **shannon1949<empty citation>**, sinyal yang tidak memuat frekuensi di atas F dapat direkonstruksi apabila dicuplik minimal $2F$ kali per detik. Audio diseragamkan pada *sr* yang sama sebelum diubah ke spektrogram.

(b). Format dan *codec*. *Dataset* yang digunakan menyimpan rekaman dalam format FLAC (*Free Lossless Audio Codec*), yaitu format kompresi audio secara *lossless* sehingga sinyal dekode identik dengan sinyal asli (**rfc9639flac**). Hal ini berbeda dengan MP3 yang menggunakan kompresi *lossy* dan membuang sebagian informasi sinyal (**brandenburg1999mp3**).

(c). Jumlah kanal dan durasi. Audio perlu diseragamkan menjadi satu kanal (mono) berdurasi tetap, agar menghasilkan spektrogram berdimensi seragam.

II.1.2 Data Citra Spektrogram

Spektrogram adalah citra dua dimensi yang memuat grafik representasi gelombang suara (*waveform*) terhadap waktu. Umumnya, grafik ini menempatkan frekuensi suara pada sumbu-Y dan waktu pada sumbu-X (**app16020572**). Spektrogram direpresentasikan sebagai matriks vektor frekuensi bertumpuk yang tiap tumpukannya mewakili magnitudo frekuensi pada bingkai waktu singkat (*analysis frame*). Pembentukkan spektrogram diilustrasikan pada Gambar **??**.



Gambar II.1 Proses Pembentukkan Spektrogram (**app16020572**)

Setiap vektor magnitudo frekuensi merupakan hasil dari transformasi ortogonal frekuensi suara terhadap waktu seperti *Discrete Fourier Transform* (DFT), *Fast Fourier Transform* (FFT), *Discrete Cosine Transform* (DCT), dan sebagainya (**mcloughlin2016speech**). Proses dilanjutkan dengan penjedelaan tiap potongan audio melalui fungsi jendela (*window function*) untuk mencegah kebocoran spektral (*spectral leakage*) dan efek tepi (*edge effect*) (**gibbs1899fourier**). Hal ini dilakukan karena fungsi jendela biasanya meredup hingga nol atau mendekati nol di tepi setiap bingkai.

Salah satu bentuk pengembangan spektrogram adalah *mel-spectrogram*. Bentuk tersebut digunakan pada TPdK ini yang akan lebih lanjut pada Subsubbab **??**. Selain itu beberapa perlakuan khusus yang harus diterapkan pada grafik spektrogram sebelum dilatih oleh model secara umum akan dijelaskan pada Subsubbab **??**

II.1.2.1 *Mel-Spectrogram*

Representasi frekuensi terhadap waktu yang dipetakan pada skala Mel disebut *mel-spectrogram*. Skala ini pertama kali digagas oleh **stevens1937mel<empty citation>** dengan menerapkan pemanfaatan data kenyaringan setara (*equal-loudness*) manusia untuk pemetaan frekuensi (Hz) ke skala non-linear sesuai dengan persepsi manusia. Pada skala ini, selisih nilai yang sama berkorespondensi dengan selisih tinggi nada yang terdengar sama bagi pendengar, sehingga resolusinya lebih rapat pada freku-

ensi rendah dan lebih renggang pada frekuensi tinggi. Secara umum, pemetaan dari frekuensi linear (f_{Hz}) ke frekuensi mel (f_{mel}) mengikuti formula komputasi di bawah:

$$f_{mel} = 2595 \log_{10} \left(1 + \frac{f_{Hz}}{700}\right) \tag{II.1}$$

Persamaan **??** di atas menunjukkan bahwa pada $f_{Hz} \leq 700$, hubungan antara f_{Hz} dan f_{mel} akan mendekati linear. Sedangkan pada $f_{Hz} > 700$ nilai mel akan bertambah semakin lambat secara logaritmik. Frekuensi Mel yang terhitung akan menjadi tumpukkan vektor seperti halnya pada spektrogram linear. Berdasarkan keserupaan tersebut, luaran yang dihasilkan adalah suatu grafik yang disebut *mel-spectrogram*.

Karena proses pembentukannya melibatkan skala Mel yang dikembangkan dari eksperimen persepsi pendengaran manusia, *mel-spectrogram* terbukti efektif untuk berbagai tugas analisis ucapan (*speech analysis*). Keefektifan tersebut berpotensi mendukung pengembangan platform ADADeH yang fokus utamanya adalah menganalisis baik ucapan asli manusia maupun ucapan sintesis buatan AI. Selain itu, model pembelajaran mendalam atau DL (*Deep Learning*) cenderung memiliki kemampuan lebih baik dalam memproses data citra dibanding data audio mentah. Model DL seperti CNN (*Convolutional Neural Network*) merupakan salah satu model dengan kemampuan tersebut. Model ini akan dijabarkan secara rinci pada Subbab **??**.

II.1.2.2 Pemrosesan Spektrogram

Meskipun spektrogram umumnya tersaji dalam bentuk citra dua dimensi yang diproses oleh model DL, pada dasarnya spektrogram adalah grafik. Hal ini menjadi kurang tepat jika pemrosesan datanya diserupakan dengan data citra lainnya. (**app16020572**) memaparkan bahwa ada beberapa penyesuian yang perlu dilakukan pada citra spektrogram. Beberapa perlakuan tersebut tersaji pada rincian di bawah:

1. Pemilihan Warna (Berwarna/RGB atau *Greyscale*)
    - Spektrogram pada dasarnya *greyscale* dengan nilai piksel 0 (putih)–1 (hitam). Pemberian warna pada spektrogram bisa saja dilakukan tapi hanya terbatas untuk keperluan visualisasi.
    - Memasukkan spektrogram berwarna pada model DL (seperti CNN) tidak menyebabkan kegagalan pembelajaran model.
    - Memasukkan spektrogram RGB pada model DL berimbas pada tinggi-

nya kompleksitas masukan (yaitu tiga kali lipat daripada *greyscale*). Hal ini disebabkan bahwa citra RGB memiliki 3 kanal atau *channel* warna, sedangkan greyscale hanya terdiri atas 1 kanal warna.

2. Invariansi Translasi dan Skala
    - Pada citra, objek yang digeser tetaplah objek yang sama. Hal ini berbeda dengan spektrogram yang memuat grafik frekuensi suara–waktu.
    - Pada spektrogram, pergeseran sepanjang waktu (sumbu-X) tidak mengubah isi suara, tetapi pergeseran sepanjang frekuensi (sumbu-Y) bisa membuatnya terdengar seperti suara lain. Informasi yang terkandung pada sumbu X dan Y punya makna yang berbeda.
    - Perubahan skala secara horizontal berimbas pada durasi (cepat atau lambatnya suara). Perubahan skala secara vertikal berimbas pada rentang frekuensi suara (tinggi atau rendahnya nada).
    - Hal penting lainnya adalah mempertahankan konsistensi parameter spektrogram pada tahap prapemrosesan dan pelatihan model. Hal ini bertujuan agar skala spektrogram yang diterima model sama sehingga model tidak salah membaca data.
3. Fitur Lokal
    - Korelasi lokal dan global pada audio berbeda sifatnya dengan pada citra.
    - Pola serupa pada rentang 0–50 Hz dan 16–18 kHz belum tentu bermakna, sedangkan pada citra bagian tekstur yang serupa (misalnya rumput) saling berkaitan dan penting untuk mendukung tugas klasifikasi.
    - Korelasi lokal sepanjang waktu lebih mirip selisih antar-frame video daripada titik yang berdekatan pada citra.

II.2 Sistem Multimedia

Menurut **bandung2025inovasi<empty citation>**, multimedia setidaknya mengacu pada penggunaan berbagai jenis media yang meliputi teks, gambar, grafik, video, audio, animasi dan sebagainya, dalam satu lingkungan terintegrasi. Lingkungan tersebut harus memiliki kapabilitas untuk memproses, menyimpan, dan mengirim media melalui jaringan komunikasi data. Lebih lanjut, terminologi sistem multimedia merujuk pada kombinasi media-media tersebut yang tersalur pada beragam aplikasi (**furht1994overview**).

Selain itu, **furht1994overview<empty citation>** juga menuturkan bahwa dalam praktiknya, sistem multimedia dapat menyimpan informasi audio dan video untuk dipakai kemudian, atau mentransmisikannya secara langsung (*live-stream*) secara *real-time*. Hal ini menyebabkan kompleksitasnya bertumpu pada seluruh komponen sis-

tem komputer, mulai dari daya pemrosesan, penyimpanan, hingga jaringan digunakan. Dalam penerapannya pada sistem komputer, sistem multimedia kian berkembang pemanfaatannya seiring dengan berkembangnya teknologi seperti pembelajaran mendalam atau *deep learning* (DL) (**li2021fundamentals**). Hal inilah yang diimplementasikan pada ADADeH.

ADADeH memposisikan sistem multimedia melalui alur pengolahan data audio. Alur ini setidaknya meliputi akuisisi, prapemrosesan, analisis model, dan penyajian model. Pada tahap akuisisi, data audio diterima dalam format FLAC (Subbab **??**) pada cuplikan tertentu (2,5–12,5 detik) yang konsisten. Selanjutnya data diolah pada tahap prapemrosesan dengan didekode ke plot gelombang audio (*waveform*), diseragamkan menjadi satu kanal dengan *sampling rate* dan durasi tetap, diurai dalam beberapa potongan (*chunks*), kemudian ditransformasi melalui *Short-Time Fourier transform* (STFT) dan *filter bank* mel, dikonversi ke skala logaritmik (dB), serta dinormalisasi menggunakan statistik data latih untuk menghasilkan *mel-spectrogram*. Selanjutnya *mel-spectrogram* akan dilatih pada model DL untuk tugas klasifikasi.

Pada tahap analisis model, *mel-spectrogram* $\mathbf{X} \in \mathbb{R}^{M \times T}$, dengan M jumlah *mel bin* dan T jumlah *frame* waktu, diperlakukan sebagai citra satu kanal dan diproses oleh *convolutional neural network* (CNN). Lapisan konvolusi mengekstraksi fitur lokal dengan menggeser filter berukuran $k_h \times k_w$ pada spektrogram, diikuti fungsi aktivasi ReLU (Persamaan **??**). Fitur yang dihasilkan diringkas oleh lapisan *pooling* dan diteruskan ke lapisan *fully connected* yang menghasilkan satu nilai skalar z (*logit*).

$$Z_k[i,j] = \max\left(0,\ b_k + \sum_{c=1}^{C_{\text{in}}} \sum_{m=0}^{k_h-1} \sum_{n=0}^{k_w-1} W_k[c,m,n]\, X_c[i+m,\ j+n]\right) \tag{II.2}$$

Nilai tersebut dikonversi menjadi probabilitas audio *deepfake* p menggunakan fungsi sigmoid (Persamaan **??**).

$$p = \sigma(z) = \frac{1}{1+e^{-z}} \tag{II.3}$$

Kemudian label prediksi $\hat{y}$ ditentukan dengan membandingkan p terhadap ambang

τ (Persamaan **??**).

$$\hat{y} = \begin{cases} 1 & \text{jika } p \geq \tau \\ 0 & \text{jika } p < \tau \end{cases} \tag{II.4}$$

Selama pelatihan, parameter model dioptimasi dengan meminimalkan *binary cross-entropy* (Persamaan **??**).

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^{N} [y_i \log p_i + (1 - y_i) \log(1 - p_i)] \tag{II.5}$$

Pada tahap penyajian hasil, ADADeH menampilkan label prediksi (asli atau *deepfake*) beserta skor keyakinan $c = \max(p,\, 1 - p)$ kepada pengguna.

II.3 Perangkat Keras dan Perangkat Lunak

Alur pengolahan audio pada Subbab **??** membutuhkan perangkat untuk menjalankannya. Berbeda dengan sistem multimedia yang bergantung pada sensor atau mikrokontroler, ADADeH seluruhnya berjalan di atas komputer umum dan layanan komputasi awan (*cloud*). Oleh karena itu, subbab ini hanya membahas perangkat yang dipakai selama pengembangan purwarupa, yaitu perangkat keras pada Subbab **??** dan perangkat lunak pada Subbab **??**.

II.3.1 Perangkat Keras

Perangkat keras pada TPdK ini dibagi berdasarkan perannya, yaitu perangkat untuk melatih model, perangkat untuk mengembangkan dan menjalankan purwarupa, serta perangkat di sisi pengguna.

II.3.1.1 Perangkat Pelatihan Model

Pelatihan model merupakan tahap yang paling berat secara komputasi. Pada tahap ini, operasi konvolusi pada Persamaan **??** dihitung berulang kali untuk seluruh *mel-spectrogram* pada data latih, dan diulang lagi di setiap *epoch* (satu putaran penuh atas data latih). Jika hanya mengandalkan CPU (*Central Processing Unit*), proses tersebut dapat memakan waktu yang sangat lama. Hal inilah yang membuat GPU (*Graphics Processing Unit*) dibutuhkan.

Tabel II.1 Spesifikasi perangkat pelatihan model pada Kaggle Notebook

Komponen	**Spesifikasi**
GPU	(isi, misalnya NVIDIA Tesla T4)
VRAM	(isi) GB
CPU	(isi jumlah inti dan tipenya)
RAM	(isi) GB
Penyimpanan	(isi) GB

GPU awalnya dirancang untuk mengolah grafis, tetapi memiliki ribuan inti kecil yang dapat mengerjakan banyak perhitungan sederhana secara bersamaan. Sifat ini cocok dengan operasi konvolusi, yang pada dasarnya adalah perkalian dan penjumlahan matriks dalam jumlah besar.

Pelatihan model ADADeH dilakukan pada Kaggle Notebook, yaitu layanan komputasi awan yang menyediakan GPU secara gratis dengan kuota waktu tertentu tiap pekan (**kaggle2026notebooks**). Layanan ini dipilih karena *dataset* yang digunakan juga tersedia di Kaggle, sehingga data dapat langsung dipasang ke *notebook* tanpa perlu diunduh dan diunggah ulang. Spesifikasi perangkat yang disediakan tersaji pada Tabel **??**. Peran tiap komponennya adalah sebagai berikut:

(a). GPU dan VRAM (*Video Random Access Memory*). GPU mengerjakan perhitungan model, sedangkan VRAM adalah memori milik GPU yang menampung parameter model beserta sekumpulan data (*batch*) yang sedang diproses. Kapasitas VRAM membatasi banyaknya *mel-spectrogram* yang dapat diproses dalam satu *batch*.

(b). CPU. Walaupun perhitungan model dikerjakan GPU, CPU tetap berperan dalam mendekode berkas FLAC, membentuk *mel-spectrogram*, dan menyusun *batch* sebelum dikirim ke GPU.

(c). RAM (*Random Access Memory*). RAM menampung data yang sedang diolah CPU. Jika kapasitasnya kurang, proses pelatihan dapat terhenti di tengah jalan.

(d). Media penyimpanan. Media ini menyimpan *dataset* audio dan berkas model hasil pelatihan yang nantinya dimuat kembali oleh purwarupa.

II.3.1.2 Perangkat Pengembangan dan Pengujian

Laptop digunakan untuk menulis kode, menyusun laporan, dan menjalankan purwarupa ADADeH. Berbeda dengan pelatihan, proses prediksi (*inference*) jauh lebih ringan. Model cukup menghitung keluaran satu kali untuk tiap potongan audio tanpa perlu memperbarui parameternya. Oleh karena itu, purwarupa dapat dijalankan pada laptop tanpa GPU khusus. Spesifikasi laptop yang digunakan tersaji pada Tabel

Tabel II.2 Spesifikasi laptop pengembangan dan pengujian

Komponen	**Spesifikasi**
Merek dan tipe	(isi)
Prosesor	(isi)
RAM	(isi) GB
Penyimpanan	(isi, misalnya SSD 512 GB)
Kartu grafis	(isi)
Sistem operasi	(isi)

??.

II.3.1.3 Perangkat Pengguna

Dari sisi pengguna, ADADeH tidak membutuhkan perangkat khusus. Pengguna cukup memiliki perangkat yang dapat menyimpan dan mengunggah rekaman audio, misalnya ponsel pintar atau laptop. Meskipun begitu, ada dua komponen pada perangkat perekam yang berpengaruh langsung pada kualitas rekaman, yaitu:

(a). Mikrofon. Seperti dijelaskan pada Subbab **??**, mikrofon menangkap gelombang suara dari udara dan mengubahnya menjadi sinyal listrik. Mikrofon bawaan ponsel sudah memadai untuk merekam ucapan, tetapi suara bising di sekitar perekam akan ikut terekam.

(b). ADC (*Analog-to-Digital Converter*). Komponen ini mencuplik sinyal listrik dari mikrofon menjadi deretan angka pada *sampling rate* tertentu. Pada ponsel, nilainya umumnya 44,1 kHz atau 48 kHz.

Kedua komponen tersebut menentukan seberapa baik rekaman yang masuk ke sistem. Hal ini berkaitan dengan batasan pada Bab I, yaitu rekaman dengan *noise* yang sangat tinggi atau durasi yang terlalu singkat dapat menurunkan akurasi deteksi. Selain itu, rekaman dari ponsel biasanya tersimpan dalam format *lossy* seperti M4A atau OGG, sehingga perlu dikonversi terlebih dahulu ke format yang diterima sistem.

II.3.2 Perangkat Lunak

Seluruh perangkat lunak yang digunakan pada TPdK ini bersifat sumber terbuka (*open source*) atau dapat dipakai secara gratis. Perangkat lunak tersebut dikelompokkan mengikuti alur pada Subbab **??**, dan ringkasannya tersaji pada Tabel **??**.

II.3.2.1 Bahasa Pemrograman dan Lingkungan Pengembangan

(a). Python. Python menjadi bahasa pemrograman utama ADADeH. Bahasa ini dipilih karena hampir semua pustaka pemrosesan audio dan DL tersedia di dalamnya, sehingga seluruh alur dari prapemrosesan hingga antarmuka dapat

ditulis dalam satu bahasa.

(b). Kaggle Notebook. Selain menyediakan perangkat keras (Subsubbab **??**), Kaggle Notebook juga menjadi tempat menulis kode pelatihan. Kode ditulis dalam sel-sel yang dapat dijalankan terpisah, dan keluarannya seperti grafik atau spektrogram langsung muncul di bawah sel. Hal ini memudahkan penulis mencoba berbagai pengaturan tanpa menjalankan ulang seluruh program.

(c). Visual Studio Code. Editor kode ini digunakan untuk menulis kode purwarupa di laptop.

(d). Git dan GitHub. Git mencatat riwayat perubahan kode, sedangkan GitHub menyimpan kode tersebut secara daring agar seluruh anggota tim dapat bekerja pada kode yang sama.

II.3.2.2 Pustaka Pemrosesan Audio

(a). librosa. Pustaka ini menangani hampir seluruh tahap prapemrosesan (**mcfee2015librosa**). Fungsinya mencakup membaca berkas audio, menyeragamkan *sampling rate* dan jumlah kanal, menghitung STFT, menerapkan *filter bank* mel, serta mengonversi hasilnya ke skala dB.

(b). SoundFile. Pustaka ini dipakai librosa untuk mendekode berkas FLAC menjadi deretan nilai amplitudo.

(c). NumPy. *Waveform* dan *mel-spectrogram* disimpan sebagai larik (*array*) NumPy (**harris2020numpy**). Pemotongan audio menjadi *chunks* dan normalisasi dilakukan sebagai operasi pada larik tersebut.

II.3.2.3 Pustaka Pembelajaran Mendalam

(a). PyTorch. Pustaka ini digunakan untuk membangun dan melatih model CNN (**paszke2019pytorch**). PyTorch menyediakan lapisan-lapisan siap pakai seperti konvolusi, *pooling*, dan *fully connected*, serta fungsi *binary cross-entropy* pada Persamaan **??**. Selain itu, PyTorch menghitung gradien secara otomatis sehingga penulis tidak perlu menurunkan rumus pembaruan parameter secara manual.

(b). CUDA dan cuDNN. Keduanya adalah perangkat lunak dari NVIDIA yang menghubungkan PyTorch dengan GPU. Tanpa keduanya, PyTorch hanya dapat berjalan di CPU. Pada Kaggle Notebook, CUDA dan cuDNN sudah terpasang.

II.3.2.4 Pustaka Evaluasi dan Visualisasi

(a). scikit-learn. Pustaka ini digunakan untuk membagi data latih dan data uji serta menghitung matriks konfusi, akurasi, dan F1-*score* (**pedregosa2011scikit**).

Tabel II.3 Ringkasan perangkat lunak yang digunakan pada ADADeH

Perangkat Lunak	**Versi**	**Peran**
Python	(isi)	Bahasa pemrograman utama
Kaggle Notebook	–	Lingkungan pelatihan model
Visual Studio Code	(isi)	Editor kode purwarupa
Git dan GitHub	(isi)	Pengelolaan versi dan kolaborasi kode
librosa	(isi)	Prapemrosesan audio dan pembentukan *mel-spectrogram*
SoundFile	(isi)	Dekode berkas FLAC
NumPy	(isi)	Penyimpanan dan pengolahan data dalam bentuk larik
PyTorch	(isi)	Pembangunan dan pelatihan model CNN
CUDA dan cuDNN	(isi)	Penghubung PyTorch dengan GPU
scikit-learn	(isi)	Pembagian data dan penghitungan metrik evaluasi
Matplotlib	(isi)	Visualisasi data dan hasil pelatihan
Streamlit	(isi)	Antarmuka pengguna berbasis web

Kurva ROC dari pustaka ini juga dipakai untuk mencari EER, yaitu titik ketika proporsi audio *deepfake* yang lolos sebagai audio asli sama besar dengan proporsi audio asli yang salah dicap *deepfake*.

(b). Matplotlib. Pustaka ini digunakan untuk menggambar *waveform*, *mel-spectrogram*, dan grafik nilai *loss* selama pelatihan (**hunter2007matplotlib**).

II.3.2.5 Perangkat Lunak Antarmuka

Antarmuka purwarupa dibangun dengan Streamlit, yaitu kerangka kerja Python untuk membuat aplikasi web sederhana tanpa perlu menulis HTML, CSS, atau JavaScript (**streamlit2026docs**). Melalui antarmuka ini, pengguna mengunggah rekaman audio dari peramban (*browser*). Sistem kemudian menjalankan seluruh alur pengolahan dan menampilkan label prediksi beserta skor keyakinannya. Cara peramban dan aplikasi saling bertukar data akan dibahas pada Subbab **??**.

Protokol komunikasi mengatur pertukaran data antarkomponen sistem, termasuk cara mengirim permintaan, menerima data, dan mengenali respons. Pada ADADeH, komunikasi tersebut menghubungkan peramban pengguna dengan aplikasi Streamlit yang menjalankan pengolahan audio. Data yang dipertukarkan berupa berkas rekaman, interaksi pengguna, dan hasil deteksi. Oleh karena itu, pembahasan protokol berkaitan dengan penyampaian rekaman secara utuh serta penyajian hasil kepada pengguna setelah pengolahan selesai.

II.3.3 Arsitektur Klien–Server dan Transportasi Data

Streamlit menggunakan arsitektur klien–server. Peramban menjadi klien yang menampilkan antarmuka, sedangkan program Python menjadi server yang menjalankan komputasi. Ketika purwarupa dijalankan secara lokal, kedua peran tersebut dapat berada pada komputer yang sama. Jika diakses melalui jaringan, perangkat pengguna dan komputer server dapat terpisah (**streamlit2026docs**). Pada rancangan ADADeH, prapemrosesan audio dan prediksi CNN berlangsung di server sehingga perangkat pengguna cukup mengirim rekaman dan menampilkan hasil.

Pada komunikasi berbasis TCP, *Transmission Control Protocol* menyediakan aliran bita yang andal dan berurutan. TCP menggunakan nomor urut, konfirmasi penerimaan, dan pengiriman ulang untuk menangani data yang hilang selama transmisi (**eddy2022tcp**). Sifat ini mendukung pengiriman berkas audio yang harus diterima secara lengkap sebelum didekode. Namun, keberhasilan transmisi hanya menunjukkan bahwa data dapat disampaikan; keterbacaan format dan kelayakan rekaman tetap perlu diperiksa oleh aplikasi.

II.3.4 HTTP dan HTTPS

Hypertext Transfer Protocol (HTTP) merupakan protokol pada lapisan aplikasi dengan pola permintaan dan respons. Klien mengirim permintaan ke suatu sumber daya, kemudian server mengembalikan respons yang memuat kode status dan, jika diperlukan, isi data. Sebagai contoh, metode GET digunakan untuk meminta representasi sumber daya, sedangkan POST meminta server memproses isi permintaan sesuai fungsi sumber daya tersebut (**fielding2022http**). Metode ini menjelaskan semantik komunikasi web; mekanisme unggah pada purwarupa mengikuti fasilitas yang disediakan Streamlit.

HTTPS melindungi komunikasi HTTP melalui *Transport Layer Security* (TLS). TLS menyediakan autentikasi pihak yang berkomunikasi, kerahasiaan data, dan pemeriksaan integritas untuk mendeteksi perubahan selama transmisi (**rescorla2018tls**). Perlindungan ini relevan karena rekaman yang diunggah dapat memuat suara dan percakapan pribadi. Apabila ADADeH diakses melalui jaringan publik, HTTPS perlu disediakan pada layanan yang menerima koneksi pengguna. Pengujian lokal dapat memakai HTTP, tetapi penggunaan HTTPS pada layanan publik harus dipastikan melalui konfigurasi penerapannya.

Tabel II.4 Peran protokol komunikasi pada rancangan ADADeH

Protokol	Peran
TCP	Menyediakan aliran bita yang andal dan berurutan pada koneksi berbasis TCP
HTTP/HTTPS	Melayani sumber daya web dan pengiriman berkas; HTTPS melindungi komunikasi dengan TLS
WebSocket/WSS	Mendukung pertukaran pesan antarmuka dan sesi; WSS melindungi koneksi dengan TLS

II.3.5 WebSocket dan Pengelolaan Sesi

WebSocket menyediakan kanal komunikasi dua arah yang tetap terbuka setelah proses pembentukan koneksi atau *handshake*. Pada mekanisme yang dijelaskan RFC 6455, koneksi diawali dengan permintaan HTTP untuk beralih ke protokol WebSocket. Setelah diterima, klien dan server dapat saling mengirim pesan melalui koneksi tersebut. Skema alamat `ws` digunakan untuk WebSocket, sedangkan `wss` menambahkan perlindungan TLS (**fette2011websocket**).

Streamlit menggunakan WebSocket untuk pertukaran pesan antarmuka dan pengelolaan sesi. Setiap tab peramban membentuk koneksi tersendiri yang berkaitan dengan sesi pengguna. Pada saat yang sama, permintaan media dan unggahan berkas melibatkan HTTP (**streamlit2026docs**). Dengan demikian, pengiriman rekaman dan pembaruan tampilan merupakan bagian komunikasi yang perlu dipahami bersama. Ketika aplikasi memakai HTTPS, koneksi WebSocket juga perlu menggunakan WSS. Ketersediaan WebSocket mendukung interaksi aplikasi, sedangkan analisis ADADeH tetap dilakukan terhadap rekaman yang telah diunggah.

II.3.6 Alur Pengiriman Audio dan Penyajian Hasil

Berdasarkan arsitektur tersebut, alur komunikasi pada purwarupa ADADeH dapat dijabarkan sebagai berikut.

(a). Peramban membuka aplikasi dan membentuk sesi untuk menerima tampilan serta mengirim interaksi pengguna.

(b). Pengguna memilih rekaman melalui `st.file_uploader`. Berkas dikirim ke server, kemudian tersedia bagi program Python sebagai objek berkas yang dapat dibaca (**streamlit2026uploader**).

(c). Aplikasi memeriksa rekaman, menjalankan prapemrosesan pada Subbab **??**, dan menghasilkan prediksi melalui model yang telah dilatih.

(d). Server memperbarui antarmuka dengan label asli atau *deepfake* beserta skor model. Jika berkas gagal dibaca atau pengolahan gagal, antarmuka perlu menyampaikan penyebabnya agar pengguna dapat memperbaiki masukan.

Ringkasan peran protokol dalam alur tersebut disajikan pada Tabel **??**. HTTP dan WebSocket berperan pada pertukaran data aplikasi, sedangkan TLS melindungi koneksi ketika digunakan melalui jaringan publik.

Ukuran unggahan perlu dibatasi dan isi berkas perlu diperiksa melalui dekode audio. Penyaringan ekstensi pada `st.file_uploader` belum menjamin kesesuaian isi berkas (**streamlit2026uploader**). Pemeriksaan ini menjaga masukan sesuai dengan batasan sistem pada Bab **??**.

II.4 Teknologi-Teknologi Lainnya

Selain representasi data dan perangkat pada subbab sebelumnya, ADADeH memerlukan dasar deteksi *deepfake audio*, model CNN, serta metode evaluasi klasifikasi. Ketiganya menjadi landasan untuk menghubungkan rekaman masukan dengan keputusan model dan menilai kemampuan sistem secara terukur.

II.4.1 Deteksi *Deepfake Audio*

Ucapan sintetis dapat dibentuk melalui *text-to-speech* (TTS), yaitu pembangkitan ucapan dari teks, atau *voice conversion* (VC), yaitu pengubahan karakteristik suara pada ucapan sumber agar menyerupai suara sasaran. Kedua teknik tersebut menjadi bagian penting dalam kajian deteksi ucapan sintetis dan hasil konversi suara (**wang2019asvspoof**). Dalam konteks ADADeH, persoalan deteksinya dirumuskan sebagai klasifikasi biner: rekaman suara asli diberi label $y = 0$, sedangkan rekaman *deepfake* diberi label $y = 1$.

Detektor mempelajari pola yang membedakan kedua kelas dari contoh berlabel. Representasi *mel-spectrogram* pada Subsubbab **??** memungkinkan pola energi terhadap frekuensi dan waktu menjadi masukan model. Akan tetapi, keberhasilan pada suatu kumpulan data belum memastikan keberhasilan pada teknik sintesis atau kondisi rekaman lain. Kajian ASVspoof menunjukkan perlunya evaluasi terhadap serangan yang belum dikenal dan variasi kondisi audio (**wang2019asvspoof**). Sesuai lingkup Bab **??**, hasil ADADeH perlu ditafsirkan dalam batas satu *dataset* berbahasa Inggris yang digunakan.

II.4.2 CNN untuk Klasifikasi Spektrogram

CNN memproses masukan melalui lapisan konvolusi untuk menghasilkan peta fitur. Pada konvolusi dua dimensi, setiap filter menggabungkan nilai dari wilayah lokal masukan dengan bobot yang dipelajari. Ukuran filter, langkah pergeseran atau *stride*, dan penambahan nilai pada tepi atau *padding* menentukan wilayah yang diproses serta dimensi keluaran (**pytorch2026conv2d**). Pada ADADeH, masukan berupa

spektrogram satu kanal dengan sumbu frekuensi dan waktu sebagaimana dijelaskan pada Subsubbab **??**.

Susunan model pada Subbab **??** menggabungkan konvolusi dan aktivasi ReLU, peringkasan melalui *pooling*, serta lapisan *fully connected* untuk menghasilkan *logit*. Konvolusi dan ReLU mengikuti Persamaan **??**, sedangkan sigmoid pada Persamaan **??** mengubah *logit* menjadi skor p untuk kelas *deepfake*. Keputusan klasifikasi kemudian mengikuti ambang pada Persamaan **??**. Dengan susunan ini, ekstraksi fitur dan klasifikasi dapat dipelajari dalam satu model.

PyTorch mendukung pembangunan model dan penghitungan gradien secara otomatis (**paszke2019pytorch**). Selama pelatihan, bobot diperbarui untuk mengurangi *binary cross-entropy* pada Persamaan **??**. Pada tahap prediksi, bobot yang telah dipelajari digunakan untuk menghitung keluaran rekaman baru. Pengaturan model dipilih melalui validasi sebagaimana dijelaskan pada Subbab **??**.

II.4.3 Pemisahan Data untuk Pelatihan dan Evaluasi

Evaluasi memerlukan pemisahan data latih, validasi, dan uji. Data latih digunakan untuk mempelajari bobot, data validasi untuk memilih pengaturan model dan ambang keputusan, serta data uji untuk menilai model setelah pilihan tersebut ditetapkan (**sklearn2026crossval**). Statistik normalisasi juga harus diperoleh dari data latih agar informasi data uji tidak memengaruhi pembentukan model (**sklearn2026pitfalls**).

Pada pengolahan rekaman menjadi beberapa potongan, seluruh potongan dari satu rekaman perlu ditempatkan pada kelompok data yang sama. Jika identitas pembicara tersedia, pemisahan berdasarkan pembicara juga perlu dipertimbangkan. Prinsip pemisahan berdasarkan kelompok mencegah contoh yang saling berkaitan muncul sekaligus pada data latih dan uji (**sklearn2026crossval**). Penerapannya pada rekaman ADADeH bertujuan mengurangi kebocoran data dan menjaga agar hasil pengujian mencerminkan kemampuan terhadap rekaman baru.

II.4.4 Metrik Evaluasi dan Interpretasi Hasil

Dengan *deepfake* sebagai kelas positif, matriks konfusi memuat empat hasil: TP untuk *deepfake* yang terdeteksi, TN untuk audio asli yang dikenali, FP untuk audio asli yang salah dianggap *deepfake*, dan FN untuk *deepfake* yang salah dianggap asli. Dari nilai tersebut, akurasi, presisi, *recall*, dan F1 dihitung menurut Persamaan **??** (**sklearn2026metrics**).

$$
\begin{aligned}
\text{Akurasi} &= \frac{TP + TN}{TP + TN + FP + FN} \\
P &= \frac{TP}{TP + FP}, \qquad R = \frac{TP}{TP + FN} \\
F_1 &= \frac{2PR}{P + R} = \frac{2TP}{2TP + FP + FN}
\end{aligned}
\tag{II.6}
$$

Akurasi menunjukkan proporsi seluruh prediksi yang benar. Presisi P menunjukkan proporsi deteksi *deepfake* yang benar, sedangkan *recall* R menunjukkan proporsi *deepfake* yang berhasil ditemukan. F1 merangkum presisi dan *recall* melalui rata-rata harmonik sehingga melengkapi akurasi, terutama ketika jumlah contoh kedua kelas berbeda (**sklearn2026metrics**). Pada laporan evaluasi, F1 perlu dinyatakan secara konsisten untuk kelas positif tersebut.

Equal Error Rate (EER) digunakan pada tugas deteksi *deepfake* ASVspoof 2021 (**delgado2021asvspoof**). Metrik ini menyatakan tingkat kesalahan ketika proporsi audio asli yang salah ditandai sebagai *deepfake* sama dengan proporsi *deepfake* yang lolos sebagai audio asli. Untuk konvensi label ADADeH, hubungan tersebut ditulis sebagai berikut.

$$
\begin{aligned}
\text{FPR}(\tau) &= \frac{FP(\tau)}{FP(\tau) + TN(\tau)} \\
\text{FNR}(\tau) &= \frac{FN(\tau)}{FN(\tau) + TP(\tau)} \\
\text{EER} &= \text{FPR}(\tau_{\text{EER}}) = \text{FNR}(\tau_{\text{EER}})
\end{aligned}
\tag{II.7}
$$

EER diperoleh dengan memvariasikan ambang skor. Pada data berhingga, titik kesamaan dapat diperkirakan melalui interpolasi atau pendekatan titik terdekat (**delgado2021asvspoof**). Ambang untuk menghitung EER pada data uji merupakan bagian pengukuran metrik, sedangkan ambang operasi purwarupa dipilih menggunakan data validasi. Kriteria Bab **??**, yaitu akurasi dan F1 minimal 90% serta EER maksimal 10%, tetap merupakan target sampai dibuktikan melalui pengujian.

Skor keyakinan yang ditampilkan juga perlu dibedakan dari frekuensi kebenaran

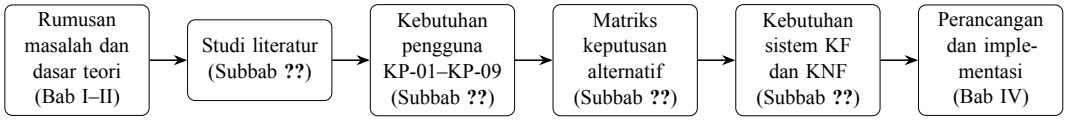
prediksi. Jaringan saraf dapat menghasilkan skor tinggi yang belum terkalibrasi dengan baik (**guo2017calibration**). Oleh karena itu, skor ADADeH perlu disajikan sebagai keluaran model, dan hasil klasifikasi digunakan sebagai indikasi awal sesuai batasan pada Bab **??**.

BAB III

ANALISIS KEBUTUHAN

Bab **??** telah merumuskan tiga persoalan utama ADADeH, yaitu cara mendeteksi anomali pada rekaman audio, cara merancang *pipeline* dari ekstraksi fitur hingga evaluasi, serta cara menyajikan hasil deteksi kepada masyarakat awam. Bab **??** kemudian menyediakan landasan teknisnya, mulai dari representasi *mel-spectrogram*, perangkat yang digunakan, hingga metrik evaluasi. Bab ini menjembatani keduanya dengan menurunkan kebutuhan yang harus dipenuhi ADADeH secara bertahap.

Alur penurunan kebutuhan diilustrasikan pada Gambar **??**. Pembahasan diawali dengan metode pengumpulan data pada Subbab **??**, dilanjutkan dengan analisis kebutuhan pengguna pada Subbab **??**. Kebutuhan pengguna tersebut menjadi dasar penilaian alternatif solusi pada Subbab **??**. Alternatif terpilih kemudian diterjemahkan menjadi kebutuhan sistem pada Subbab **??**, yang menjadi acuan perancangan pada Bab IV.



Gambar III.1 Alur Penurunan Kebutuhan ADADeH

III.1 Metode Pengumpulan Data

Data pada TPdK ini dikumpulkan melalui studi literatur. Metode ini dipilih karena tiga alasan. Pertama, pengguna sasaran ADADeH adalah korban kejahatan, sehingga pengambilan data langsung dari korban memerlukan pertimbangan etika dan perizinan di luar lingkup purwarupa pada Bab **??**. Kedua, karakteristik *deepfake audio* dan kondisi rekaman di dunia nyata telah dikaji secara luas melalui tantangan ASVspoof dan penelitian turunannya. Ketiga, pedoman interaksi manusia–AI serta regulasi pelindungan data tersedia sebagai dokumen yang dapat ditelaah langsung.

III.1.1 Tahapan Studi Literatur

Studi literatur dilakukan melalui enam tahap yang tersaji pada Gambar **??**. Tahap pertama adalah merumuskan pertanyaan kajian (PK) yang diturunkan dari rumusan

masalah (RM) pada Bab **??**, yaitu:

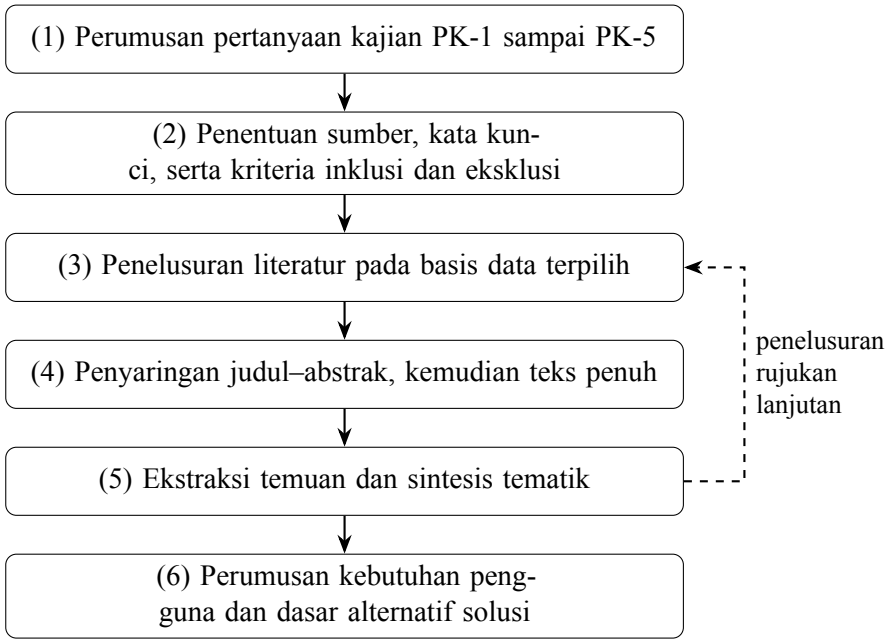
PK-1. Kondisi dan kendala apa yang dihadapi pengguna awam ketika menerima rekaman suara yang dicurigai sebagai *deepfake*? (RM-1 dan RM-3)

PK-2. Bagaimana karakteristik rekaman di dunia nyata memengaruhi kinerja detektor *deepfake audio*? (RM-1 dan RM-2)

PK-3. Bagaimana hasil sistem berbasis AI sebaiknya disajikan kepada pengguna awam? (RM-3)

PK-4. Kewajiban apa yang melekat pada pemrosesan rekaman suara sebagai data pribadi? (RM-3)

PK-5. Pendekatan deteksi apa saja yang tersedia beserta kebutuhan sumber dayanya? (RM-1 dan RM-2)



Gambar III.2 Tahapan Studi Literatur

Tahap kedua menetapkan sumber, kata kunci, serta kriteria seleksi sebagaimana tersaji pada Tabel **??**. Pada tahap ketiga dan keempat, literatur ditelusuri lalu disaring dua kali, yaitu berdasarkan judul dan abstrak, kemudian berdasarkan teks penuh. Daftar pustaka dari literatur yang lolos juga ditelusuri untuk menemukan rujukan lanjutan. Tahap kelima mengelompokkan temuan ke dalam tema, dan tahap keenam menerjemahkan tiap tema menjadi kebutuhan.

III.1.2 Hasil Studi Literatur

Literatur yang lolos penyaringan dikelompokkan ke dalam enam tema pada Tabel **??**. Tema T1 sampai T5 menjadi dasar kebutuhan pengguna pada Subbab **??**, sedangkan tema T6 menjadi dasar alternatif solusi pada Subbab **??**.

Tabel III.1 Sumber, kata kunci, dan kriteria seleksi literatur

Aspek	**Rincian**
Basis data	IEEE Xplore, ISCA Archive, ACM Digital Library, ScienceDirect, arXiv, PLOS ONE, MDPI, Google Scholar, serta JDIH untuk regulasi
Kata kunci	*audio deepfake detection*, *spoofing countermeasure*, ASVspoof, *human detection of speech deepfakes*, *voice cloning scam*, *speech privacy*, *human-AI interaction guidelines*, pelindungan data pribadi
Rentang tahun	2017–2026, kecuali rujukan dasar yang masih menjadi acuan
Kriteria inklusi	Artikel jurnal atau prosiding bertelaah sejawat, laporan resmi, dokumentasi teknis, atau regulasi; berbahasa Inggris atau Indonesia; menjawab sedikitnya satu PK
Kriteria eksklusi	Teks penuh tidak dapat diakses; tidak memuat metode atau data evaluasi; berfokus pada *deepfake* visual tanpa komponen audio; duplikasi publikasi

III.2 Analisis Kebutuhan Pengguna

Berdasarkan hasil studi literatur pada Subbab **??**, kebutuhan pengguna ADADeH dirumuskan pada subbab ini. Kebutuhan pengguna adalah kemampuan yang harus dimiliki sistem dari sudut pandang pengguna, belum menyangkut cara pemenuhannya secara teknis.

III.2.1 Identifikasi Pengguna

ADADeH ditujukan bagi dua kelompok pengguna berikut.

(a). **Pengguna awam.** Kelompok ini merupakan pengguna utama, yaitu korban atau calon korban kejahatan berbasis *deepfake audio*. Kelompok ini tidak memiliki latar belakang pemrosesan sinyal maupun forensik digital, sehingga membutuhkan keluaran yang langsung dapat dipahami.

(b). **Pendamping pelaporan.** Kelompok ini mencakup pihak yang membantu korban menyiapkan laporan, misalnya keluarga, pendamping hukum, atau petugas penerima aduan. Kelompok ini membutuhkan keluaran yang dapat disimpan atau dilampirkan sebagai indikasi awal, dengan kesadaran bahwa hasil tersebut bukan pengganti pemeriksaan ahli.

III.2.2 Rumusan Kebutuhan Pengguna

Kebutuhan pengguna diberi kode KP-01 sampai KP-09 dan diuraikan sebagai berikut.

KP-01. **Pengguna membutuhkan sarana pemeriksaan keaslian rekaman yang dapat diakses secara mandiri.**
Laporan **mcafee2023impostor<empty citation>** terhadap lebih dari 7.000

responden di tujuh negara menunjukkan bahwa satu dari empat responden pernah mengalami atau mengenal korban penipuan kloning suara, dan sebagian besar korban mengalami kerugian finansial. Di sisi lain, **mai2023warning<empty citation>** menemukan bahwa pendengar hanya mampu mengenali sekitar 73% sampel *deepfake*, dan pemberian contoh sebelumnya hanya sedikit meningkatkan kemampuan tersebut. Karena pemeriksaan melalui laboratorium forensik digital terbatas (**SIP_Law_Firm_2025**), pengguna membutuhkan sarana deteksi otomatis yang dapat dipakai tanpa melalui prosedur kelembagaan terlebih dahulu.

KP-02. **Pengguna membutuhkan sistem yang menerima rekaman dari perangkat sehari-hari.**
Rekaman pengguna umumnya berasal dari ponsel dan tersimpan dalam format *lossy* seperti M4A atau OGG (Subsubbab **??**). Tugas *deepfake* pada ASVspoof 2021 secara khusus menyoroti audio terkompresi, dan hasilnya menunjukkan bahwa detektor masih kurang mampu menggeneralisasi lintas sumber data (**liu2023asvspoof2021**). Sistem karena itu harus menerima berkas tersebut dan menyeragamkannya sendiri, tanpa menuntut pengguna melakukan konversi format secara manual.

KP-03. **Pengguna membutuhkan keluaran berupa kesimpulan yang langsung dapat dipahami.**
Pedoman interaksi manusia–AI menganjurkan agar sistem menjelaskan apa yang dapat dilakukannya serta seberapa baik kinerjanya (**amershi2019guidelines**). Bagi pengguna awam, hal ini berarti pernyataan "terindikasi asli" atau "terindikasi *deepfake*" beserta tingkat keyakinannya, bukan nilai *logit* atau grafik spektrum. Kebutuhan ini sejalan dengan penyajian skor keyakinan $c = \max(p,\, 1 - p)$ pada Subbab **??**.

KP-04. **Pengguna membutuhkan keterangan mengenai keterbatasan hasil.**
Keluaran ADADeH berkaitan dengan kepentingan hukum (**Iman_2026**). Selain itu, **muller2022generalize<empty citation>** menunjukkan bahwa kinerja detektor yang baik pada data tolok ukur dapat turun tajam pada rekaman dunia nyata, sedangkan skor jaringan saraf belum tentu terkalibrasi (**guo2017calibration**). Sistem karena itu harus menegaskan bahwa hasil merupakan indikasi awal, model dilatih pada satu *dataset* berbahasa Inggris, dan hasil tidak menggantikan pemeriksaan forensik digital oleh ahli.

KP-05. **Pengguna membutuhkan hasil dalam waktu yang singkat.**
Penipuan kloning suara memanfaatkan kedekatan emosional dan rasa mendesak agar korban segera bertindak (**mcafee2023impostor**). Pemeriksaan kare-

na itu kerap dilakukan dalam situasi tertekan. Menurut **nielsen1993response<empty citation>**, sekitar 10 detik adalah batas pengguna dapat mempertahankan perhatian saat menunggu, dan penundaan yang lebih lama memerlukan indikator kemajuan.

KP-06. **Pengguna membutuhkan sistem yang dapat memeriksa rekaman berdurasi panjang.**

Rekaman percakapan dapat berlangsung beberapa menit, sedangkan model bekerja pada potongan berdurasi tetap (Subbab **??**). **muller2022generalize<empty citation>** juga menemukan bahwa masukan sepanjang 4 detik belum memberikan kinerja maksimal dibanding masukan yang lebih panjang. Pengguna karena itu membutuhkan satu kesimpulan menyeluruh atas seluruh rekaman yang diunggah, bukan daftar hasil per potongan.

KP-07. **Pengguna membutuhkan peringatan ketika mutu rekaman tidak memadai.**

Evaluasi detektor pada audio berderau masih terbatas (**almutairi2022review**). **muller2021silence<empty citation>** juga menemukan bahwa durasi keheningan pada ASVspoof 2019 berkorelasi dengan label, sehingga model dapat "belajar" dari keheningan alih-alih dari ciri ucapan. Rekaman yang terlalu singkat, didominasi keheningan, atau mengandung derau tinggi karena itu berisiko menghasilkan keputusan yang kurang dapat dipercaya. Pengguna perlu diberi tahu hal tersebut agar tidak menyimpulkan secara keliru.

KP-08. **Pengguna membutuhkan jaminan kerahasiaan atas rekaman yang diunggah.**

Rekaman ucapan merupakan sumber data pribadi yang kaya, mulai dari informasi kesehatan hingga ciri biometrik penutur (**nautsch2019privacy**). Undang-Undang Nomor 27 Tahun 2022 menggolongkan data biometrik sebagai data pribadi yang bersifat spesifik dan mewajibkan pemrosesan yang terbatas, spesifik, dan sesuai tujuannya (**uupdp2022**). Pengguna membutuhkan kepastian bahwa berkas tidak disebarluaskan dan tidak disimpan melebihi keperluan pemrosesan.

KP-09. **Pendamping pelaporan membutuhkan ringkasan hasil yang dapat disimpan.**

Deepfake audio berpotensi dipakai untuk memanipulasi alat bukti elektronik (**Iman_2026**), sementara pemeriksaan ahli memerlukan waktu (**SIP_Law_Firm_2025**). Pendamping membutuhkan ringkasan yang mencatat identitas berkas yang diperiksa, waktu pemeriksaan, dan hasilnya, sehingga dapat dilampirkan sebagai indikasi awal ketika rekaman diserahkan kepada pihak berwenang.

III.2.3 Keterlacakan Kebutuhan

Agar setiap kebutuhan dapat ditelusuri asalnya, Tabel **??** memetakan kebutuhan pengguna terhadap tema literatur pada Tabel **??** dan rumusan masalah pada Bab **??**. Pemetaan ini sekaligus memastikan tidak ada kebutuhan yang dirumuskan tanpa dasar.

Kesembilan kebutuhan tersebut menjadi dasar penilaian alternatif solusi pada subbab berikutnya. Alternatif terpilih kemudian diterjemahkan menjadi kebutuhan sistem yang bersifat teknis.

III.3 Pemilihan Alternatif Solusi

Seluruh alternatif pada subbab ini memakai platform yang sama, yaitu aplikasi web Streamlit yang memproses rekaman di sisi server (Subbab **??**). Akibatnya, kebutuhan yang berkaitan dengan antarmuka dan privasi (KP-03, KP-04, KP-08, dan KP-09) dapat dipenuhi setara oleh semua alternatif. Perbedaan antaralternatif terletak pada pendekatan deteksinya, sehingga penilaian difokuskan pada aspek tersebut.

III.3.1 Alternatif Solusi

Berdasarkan tema T6 pada Tabel **??**, empat alternatif pendekatan deteksi dipertimbangkan.

(A1). **Fitur *cepstral* dengan pengklasifikasi klasik.** Rekaman diringkas menjadi fitur MFCC, LFCC, atau CQCC, kemudian diklasifikasi menggunakan GMM atau SVM. CQCC dengan GMM terbukti efektif sebagai *countermeasure*, tetapi konfigurasinya sensitif terhadap jenis serangan dan skenario penggunaan (**todisco2017cqcc**). Pendekatan ini sangat ringan, tetapi daya pembedanya terbatas pada ciri yang dirancang secara manual.

(B2). **CNN pada *mel-spectrogram*.** *Mel-spectrogram* diperlakukan sebagai citra satu kanal dan diklasifikasi oleh CNN, sebagaimana dijelaskan pada Subbab **??** dan **??**. Sistem berbasis CNN ringan (LCNN) pada fitur spektral mencapai EER 1,86% pada skenario *logical access* ASVspoof 2019 (**lavrentyeva2019stc**). Model berukuran kecil hingga menengah dan dapat dijalankan pada CPU.

(C3). **Model *end-to-end* pada *waveform* mentah.** Model seperti RawNet2 (**tak2021rawnet2**) dan AASIST (**jung2022aasist**) menerima deretan sampel audio secara langsung sehingga fitur dipelajari sepenuhnya oleh jaringan. AASIST memodelkan artefak spektral dan temporal melalui *graph attention*, dan varian ringannya hanya memiliki sekitar 85 ribu parameter. Namun, pemrosesan pada resolusi sampel penuh dan arsitektur yang lebih kompleks menambah beban pelatihan serta penyesuaian.

(D4). **Model *self-supervised* pralatih.** *Front-end* wav2vec 2.0 XLS-R yang telah dilatih pada data ucapan berskala besar disetel ulang (*fine-tuning*) bersama *back-end* AASIST dan augmentasi data. Pendekatan ini melaporkan EER terendah pada basis data ASVspoof 2021 *logical access* dan *deepfake* saat dipublikasikan (**tak2022wav2vec**). Kekurangannya, *front-end* tersebut berukuran sekitar 300 juta parameter sehingga berat untuk dilatih dan dijalankan tanpa GPU.

III.3.2 Kriteria Penilaian

Kriteria penilaian beserta bobotnya tersaji pada Tabel **??**. Bobot terbesar diberikan pada kinerja deteksi karena kriteria tersebut merupakan syarat keberhasilan utama pada Bab **??**. Kebutuhan sumber daya pelatihan dan waktu inferensi diberi bobot berikutnya karena keduanya merupakan batasan nyata pada Subbab **??**. Kemudahan implementasi serta ketahanan terhadap kondisi rekaman melengkapi penilaian.

Setiap alternatif diberi skor s_{ij} pada skala 1 (sangat kurang) sampai 5 (sangat baik) untuk setiap kriteria. Skor akhir alternatif j dihitung sebagai jumlah skor terbobot pada Persamaan **??**, dengan w_i bobot kriteria ke-i dan $\sum_i w_i = 1$.

$$S_j = \sum_{i=1}^{5} w_i \, s_{ij} \tag{III.1}$$

III.3.3 Matriks Keputusan

Hasil penilaian tersaji pada Tabel **??**. Dasar pemberian skor untuk setiap alternatif adalah sebagai berikut.

(a). **A1** unggul pada K2 dan K3 karena tidak memerlukan GPU. Namun, skornya rendah pada K1 dan K5 karena sistem berbasis DL secara konsisten melampaui pendekatan klasik pada tantangan ASVspoof (**lavrentyeva2019stc**), sedangkan konfigurasi CQCC sensitif terhadap jenis serangan (**todisco2017cqcc**).

(b). **A2** memiliki kinerja yang kompetitif (**lavrentyeva2019stc**) dengan model yang cukup kecil untuk dilatih dalam kuota Kaggle dan dijalankan pada CPU. Pustaka librosa dan PyTorch (Subbab **??**) mendukung seluruh tahapnya. Skor K5 bernilai sedang karena **muller2022generalize<empty citation>** melaporkan bahwa fitur *mel-spectrogram* rata-rata kalah dibanding spektrogram logaritmik atau CQT.

(c). **A3** berpotensi menangkap artefak yang tidak tampak pada fitur rancangan ma-

nual (**tak2021rawnet2**), tetapi pemrosesan pada resolusi sampel penuh serta arsitektur *graph attention* (**jung2022aasist**) menambah beban pelatihan, inferensi, dan penyesuaian.

(d). **A4** memiliki kinerja dan ketahanan tertinggi (**tak2022wav2vec**), tetapi ukuran *front-end* yang besar membuatnya paling berat pada K2, K3, dan K4.

Untuk memeriksa apakah keputusan bergantung pada pilihan bobot, perhitungan diulang dengan dua skema bobot lain. Hasilnya tersaji pada Tabel **??**. Pada skema kedua, bobot K1 dinaikkan menjadi 0,40 dan bobot kriteria lain diturunkan secara proporsional. Pada skema ketiga, seluruh kriteria diberi bobot sama.

III.3.4 Solusi Terpilih

Alternatif A2, yaitu CNN pada *mel-spectrogram*, memperoleh skor tertinggi pada ketiga skema bobot. Dengan demikian, keputusan tidak bergantung pada satu pilihan bobot tertentu. A2 dipilih karena menyeimbangkan kinerja deteksi dengan keterbatasan perangkat pada Subbab **??**, dan sejalan dengan landasan teori pada Bab **??**.

Pilihan ini membawa satu risiko yang perlu dicatat, yaitu temuan **muller2022generalize<empty citation>** bahwa fitur *mel-spectrogram* dapat kalah dibanding spektrogram logaritmik. Sesuai pendekatan CRISP-DM pada Bab **??**, apabila evaluasi belum memenuhi target, representasi masukan dapat diganti dengan spektrogram logaritmik tanpa mengubah arsitektur sistem secara keseluruhan. Alternatif A4 tetap menjadi arah pengembangan lanjutan apabila sumber daya komputasi yang lebih besar tersedia.

III.4 Analisis Kebutuhan Sistem

Kebutuhan pengguna pada Subbab **??** dan solusi terpilih pada Subbab **??** diterjemahkan menjadi kebutuhan sistem. Kebutuhan sistem dibagi menjadi kebutuhan fungsional (KF), yaitu apa yang harus dilakukan sistem, dan kebutuhan nonfungsional (KNF), yaitu mutu yang harus dipenuhi sistem saat melakukannya.

III.4.1 Kebutuhan Fungsional

Kebutuhan fungsional ADADeH tersaji pada Tabel **??**. KF-02 sampai KF-08 dijalankan berurutan secara otomatis setelah pengguna mengunggah berkas, sehingga memenuhi kriteria keberhasilan kedua pada Bab **??**, yaitu *pipeline* yang berjalan tanpa intervensi manual.

Agregasi pada KF-07 dilakukan dengan merata-ratakan skor seluruh potongan, sebagaimana tersaji pada Persamaan **??**. Skor rekaman $\bar{p}$ kemudian menggantikan p pada Persamaan **??** untuk menentukan label, dan skor keyakinan c dihitung dari nilai